

# 2017-02-01 Spark 學習筆記

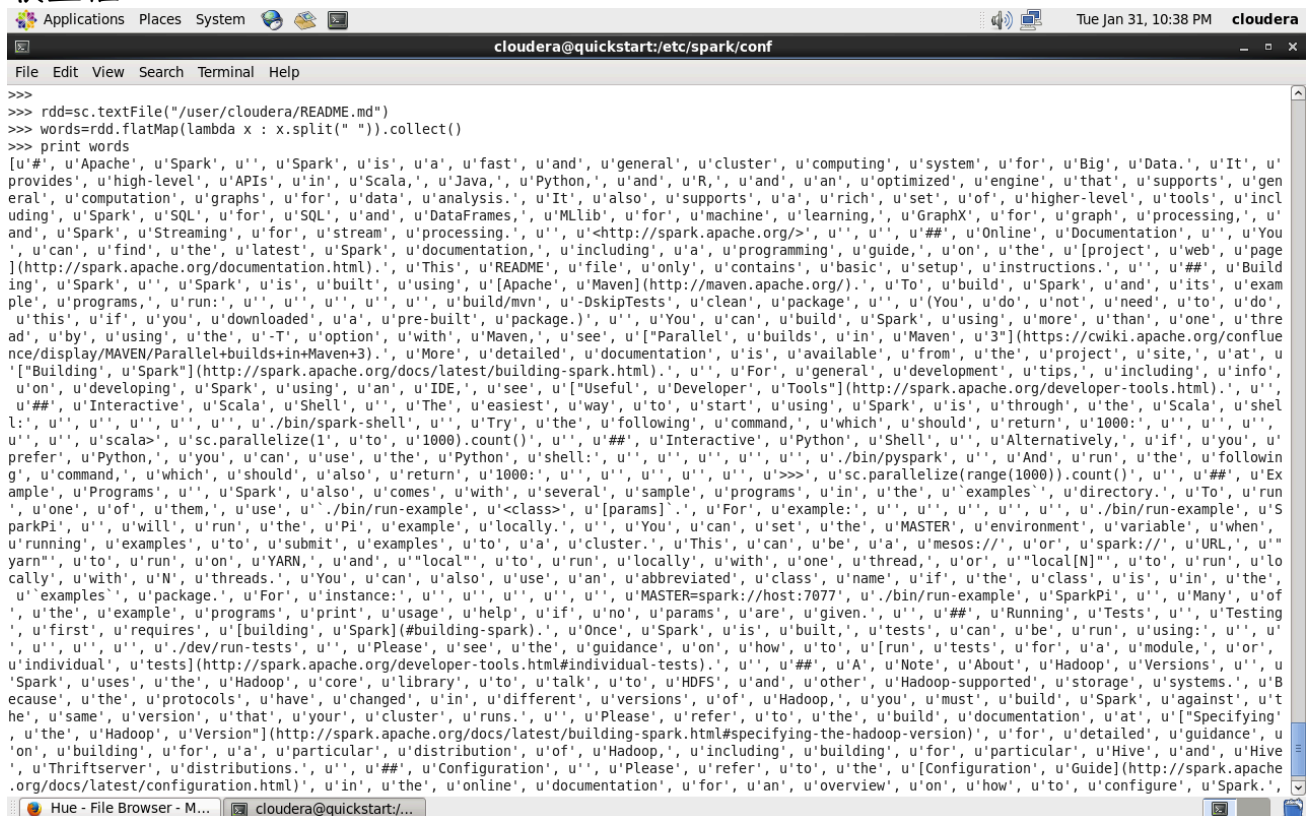
用flatMap+ReduceByKey做WordCount計算

參考：Spark學習手冊 p.53

Step1：先將README.md上傳到HDFS上面

Step2：sc.textFile()讀取檔案，並且建立一個RDD字串

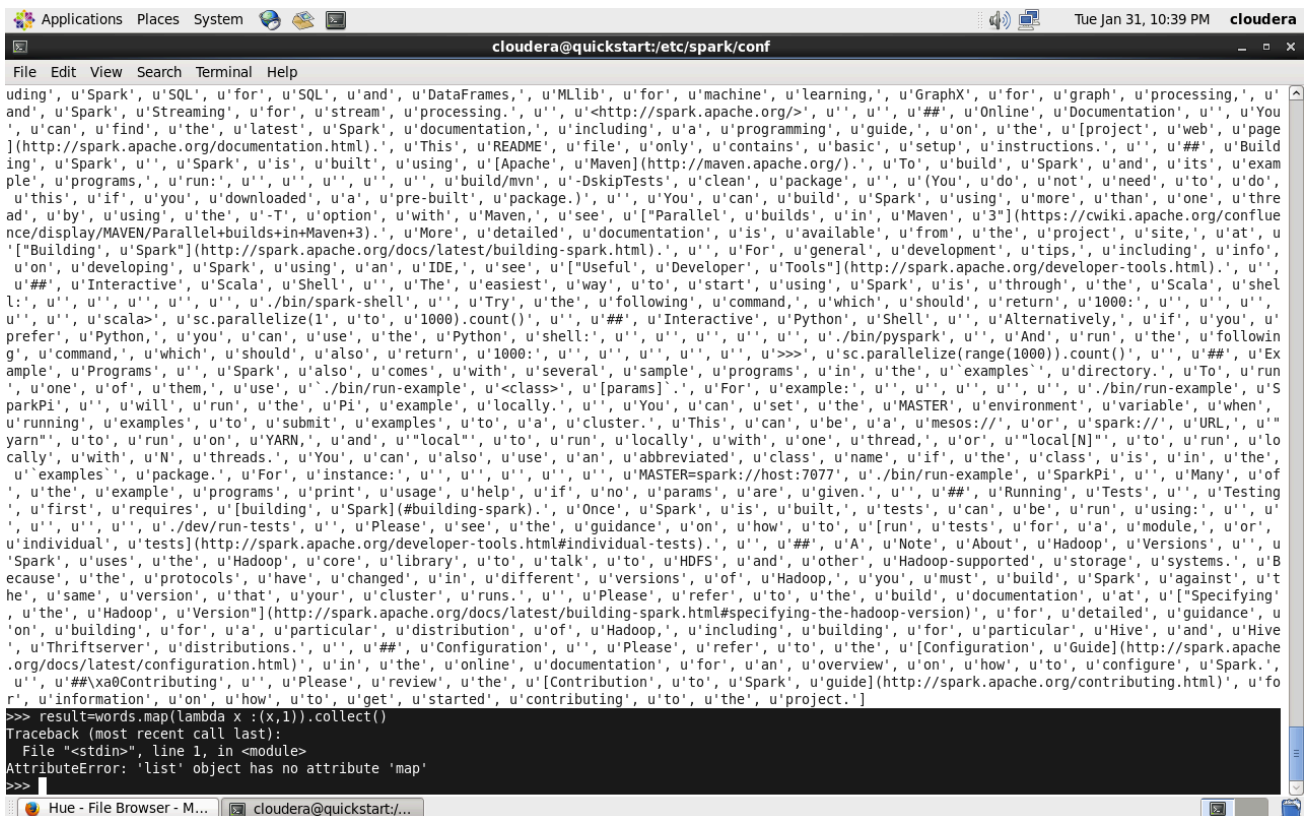
Step3：使用flatMap()產生一個單字以及數字1的pairRDD，並使用collect()接收整個RDD



```
>>> rdd=sc.textFile("/user/cloudera/README.md")
>>> words=rdd.flatMap(lambda x : x.split(" ")).collect()
>>> print words
[u' ', u'Apache', u'Spark', u'', u'Spark', u'is', u'a', u'fast', u'and', u'general', u'cluster', u'computing', u'system', u'for', u'Big', u'Data', u'It', u'
provides', u'high-level', u'APIs', u'in', u'Scala', u'Java', u'Python', u'and', u'R', u'and', u'an', u'optimized', u'engine', u'that', u'supports', u'gen
eral', u'computation', u'graphs', u'for', u'data', u'analysis', u'It', u'also', u'supports', u'a', u'rich', u'set', u'of', u'higher-level', u'tools', u'incl
uding', u'Spark', u'SQL', u'for', u'SQL', u'and', u>DataFrames', u'MLlib', u'for', u'machine', u'learning', u'GraphX', u'for', u'graph', u'processing', u'
and', u'Spark', u'Streaming', u'for', u'stream', u'processing', u'', u'<http://spark.apache.org/>', u'', u'', u'##', u'Online', u'Documentation', u'', u'You
', u'can', u'find', u'the', u'latest', u'Spark', u'documentation', u'including', u'a', u'programming', u'guide', u'on', u'the', u'[project', u'web', u'page
](http://spark.apache.org/documentation.html)', u'This', u'README', u'file', u'only', u'contains', u'basic', u'setup', u'instructions', u'', u'##', u'Build
ing', u'Spark', u'', u'Spark', u'is', u'built', u'using', u'[Apache', u'Maven](http://maven.apache.org/)', u'To', u'build', u'Spark', u'and', u'its', u'exam
ple', u'programs', u'run:', u'', u'', u'', u'', u'', u'build/mvn', u'DskipTests', u'clean', u'package', u'', u'(You', u'do', u'not', u'need', u'to', u'do',
u'this', u'if', u'you', u'downloaded', u'a', u'pre-built', u'package.)', u'', u'You', u'can', u'build', u'Spark', u'using', u'more', u'than', u'one', u'thre
ad', u'by', u'using', u'the', u'-T', u'option', u'with', u'Maven', u'see', u'["Parallel', u'builds', u'in', u'Maven', u'3"]](https://wiki.apache.org/conflue
nce/display/MAVEN/Parallel+builds+in+Maven+3)', u'More', u'detailed', u'documentation', u'is', u'available', u'from', u'the', u'project', u'site', u'at', u
'["Building', u'Spark"]](http://spark.apache.org/docs/latest/building-spark.html)', u'', u'For', u'general', u'development', u'tips', u'including', u'info',
u'on', u'developing', u'Spark', u'using', u'an', u'IDE', u'see', u'["Useful', u'Developer', u'Tools"]](http://spark.apache.org/developer-tools.html)', u'',
u'##', u'Interactive', u'Scala', u'Shell', u'', u'The', u'easiest', u'way', u'to', u'start', u'using', u'Spark', u'is', u'through', u'the', u'Scala', u'shel
l:', u'', u'', u'', u'', u'', u'./bin/spark-shell', u'', u'Try', u'the', u'following', u'command', u'which', u'should', u'return', u'1000:', u'', u'', u'',
u'', u'', u'scala>', u'sc.parallelize(1', u'to', u'1000).count()', u'', u'##', u'Interactive', u'Python', u'Shell', u'', u'Alternatively', u'if', u'you', u'
prefer', u'Python', u'you', u'can', u'use', u'the', u'Python', u'shell:', u'', u'', u'', u'', u'', u'./bin/pyspark', u'', u'And', u'run', u'the', u'followin
g', u'command', u'which', u'should', u'also', u'return', u'1000:', u'', u'', u'', u'', u'', u'>>>', u'sc.parallelize(range(1000)).count()', u'', u'##', u'Ex
ample', u'Programs', u'', u'Spark', u'also', u'comes', u'with', u'several', u'sample', u'programs', u'in', u'the', u'examples', u'directory', u'To', u'run
', u'one', u'of', u'them', u'use', u'./bin/run-example', u'<class>', u'[params]', u'For', u'example:', u'', u'', u'', u'', u'', u'./bin/run-example', u'S
parkPi', u'', u'will', u'run', u'the', u'Pi', u'example', u'locally', u'', u'You', u'can', u'set', u'the', u'MASTER', u'environment', u'variable', u'when',
u'running', u'examples', u'to', u'submit', u'examples', u'to', u'a', u'cluster', u'This', u'can', u'be', u'a', u'mesos://', u'or', u'spark://', u'URL', u'
yarn', u'to', u'run', u'on', u'YARN', u'and', u'local', u'to', u'run', u'locally', u'with', u'one', u'thread', u'or', u'local[N]', u'to', u'run', u'lo
cally', u'with', u'N', u'threads', u'You', u'can', u'also', u'use', u'an', u'abbreviated', u'class', u'name', u'if', u'the', u'class', u'is', u'in', u'the',
u'examples', u'package', u'For', u'instance:', u'', u'', u'', u'', u'', u'MASTER=spark://host:7077', u'./bin/run-example', u'SparkPi', u'', u'Many', u'of
', u'the', u'examples', u'programs', u'print', u'usage', u'help', u'if', u'no', u'params', u'are', u'given', u'', u'##', u'Running', u'Tests', u'', u'Testing
', u'first', u'requires', u'[building', u'Spark](#building-spark)', u'Once', u'Spark', u'is', u'built', u'tests', u'can', u'be', u'run', u'using:', u'', u'
', u'', u'', u'', u'./dev/run-tests', u'', u'Please', u'see', u'the', u'guidance', u'on', u'how', u'to', u'[run', u'tests', u'for', u'a', u'module', u'or',
u'individual', u'tests](http://spark.apache.org/developer-tools.html#individual-tests)', u'', u'##', u'A', u'Note', u>About', u'Hadoop', u'Versions', u'', u
'Spark', u'uses', u'the', u'Hadoop', u'core', u'library', u'to', u'talk', u'to', u'HDFS', u'and', u'other', u'Hadoop-supported', u'storage', u'systems', u'B
ecause', u'the', u'protocols', u'have', u'changed', u'in', u'different', u'versions', u'of', u'Hadoop', u'you', u'must', u'build', u'Spark', u'against', u't
he', u'same', u'version', u'that', u'your', u'cluster', u'runs', u'', u'Please', u'refer', u'to', u'the', u'build', u'documentation', u'at', u'["Specifying',
u'the', u'Hadoop', u'Version"]](http://spark.apache.org/docs/latest/building-spark.html#specifying-the-hadoop-version)', u'for', u'detailed', u'guidance', u
'on', u'building', u'for', u'a', u'particular', u'distribution', u'of', u'Hadoop', u'including', u'building', u'for', u'particular', u'Hive', u'and', u'Hive
', u'ThriftServer', u'distributions', u'', u'##', u'Configuration', u'', u'Please', u'refer', u'to', u'the', u'[Configuration', u'Guide](http://spark.apache
.org/docs/latest/configuration.html)', u'in', u'the', u'online', u'documentation', u'for', u'an', u'overview', u'on', u'how', u'to', u'configure', u'Spark',
```

Step4：使用flatMap()產生一個單字以及數字1的pairRDD，並使用collect()接收整個RDD

結果就產生Error了！！！！~~~~



=====

## Error錯誤排解

#原因：因為如果在flatMap的時候使用collect，command回傳的型態是list而不是一個RDD，所以只有把它移掉即可

#參考網站：<http://stackoverflow.com/questions/40281834/list-object-has-no-attribute-map>

=====

```
Applications Places System Tue Jan 31, 10:40 PM cloudera
cloudera@quickstart:/etc/spark/conf
File Edit View Search Terminal Help
>>>
>>> rdd=sc.textFile("/user/cloudera/README.md")
>>> words=rdd.flatMap(lambda x : x.split(" "))
>>> result=words.map(lambda x : (x,1)).collect()
>>> print result
[(u'#', 1), (u'Apache', 1), (u'Spark', 1), (u'', 1), (u'Spark', 1), (u'is', 1), (u'a', 1), (u'fast', 1), (u'and', 1), (u'general', 1), (u'cluster', 1), (u'com
puting', 1), (u'system', 1), (u'for', 1), (u'Big', 1), (u'Data', 1), (u'It', 1), (u'provides', 1), (u'high-level', 1), (u'APIs', 1), (u'in', 1), (u'Scala',
, 1), (u'Java', 1), (u'Python', 1), (u'and', 1), (u'R', 1), (u'and', 1), (u'an', 1), (u'optimized', 1), (u'engine', 1), (u'that', 1), (u'supports', 1), (u
'general', 1), (u'computation', 1), (u'graphs', 1), (u'for', 1), (u'data', 1), (u'analysis', 1), (u'It', 1), (u'also', 1), (u'supports', 1), (u'a', 1), (u'r
ich', 1), (u'set', 1), (u'of', 1), (u'higher-level', 1), (u'tools', 1), (u'inclusing', 1), (u'Spark', 1), (u'SQL', 1), (u'for', 1), (u'SQL', 1), (u'and', 1),
(u'DataFrames', 1), (u'Mllib', 1), (u'for', 1), (u'machine', 1), (u'learning', 1), (u'GraphX', 1), (u'for', 1), (u'graph', 1), (u'processing', 1), (u'and
', 1), (u'Spark', 1), (u'Streaming', 1), (u'for', 1), (u'stream', 1), (u'processing', 1), (u'', 1), (u'<http://spark.apache.org/>', 1), (u'', 1), (u'', 1),
(u'##', 1), (u'Online', 1), (u'Documentation', 1), (u'', 1), (u'You', 1), (u'can', 1), (u'find', 1), (u'the', 1), (u'latest', 1), (u'Spark', 1), (u'documenta
tion', 1), (u'inclusing', 1), (u'a', 1), (u'programming', 1), (u'guide', 1), (u'on', 1), (u'the', 1), (u'project', 1), (u'web', 1), (u'page)(http://spark.
apache.org/documentation.html', 1), (u'This', 1), (u'This', 1), (u'README', 1), (u'file', 1), (u'only', 1), (u'contains', 1), (u'basic', 1), (u'setup', 1), (u'instructio
ns', 1), (u'', 1), (u'##', 1), (u'Building', 1), (u'Spark', 1), (u'', 1), (u'Spark', 1), (u'is', 1), (u'built', 1), (u'using', 1), (u'[Apache', 1), (u'Maven
][http://maven.apache.org/)', 1), (u'To', 1), (u'build', 1), (u'Spark', 1), (u'and', 1), (u'its', 1), (u'example', 1), (u'programs', 1), (u'run:', 1), (u'',
, 1), (u'', 1), (u'', 1), (u'', 1), (u'build/mvn', 1), (u'DskipTests', 1), (u'clean', 1), (u'package', 1), (u'', 1), (u'(You', 1), (u'do', 1), (u'
not', 1), (u'need', 1), (u'to', 1), (u'do', 1), (u'this', 1), (u'if', 1), (u'you', 1), (u'downloaded', 1), (u'a', 1), (u'a', 1), (u'pre-built', 1), (u'package', 1), (
u'', 1), (u'You', 1), (u'can', 1), (u'build', 1), (u'Spark', 1), (u'using', 1), (u'more', 1), (u'than', 1), (u'one', 1), (u'thread', 1), (u'by', 1), (u'using
', 1), (u'the', 1), (u'T', 1), (u'option', 1), (u'with', 1), (u'Maven', 1), (u'see', 1), (u'Parallel', 1), (u'builds', 1), (u'in', 1), (u'Maven', 1), (u'
3'](<http://wiki.apache.org/confluence/display/MAVEN/Parallel+builds+in+Maven+3>)', 1), (u'More', 1), (u'detailed', 1), (u'documentation', 1), (u'is', 1), (
u'available', 1), (u'from', 1), (u'the', 1), (u'project', 1), (u'site', 1), (u'at', 1), (u'["Building', 1), (u'Spark'](<http://spark.apache.org/docs/latest/b
uilding-spark.html>)', 1), (u'', 1), (u'for', 1), (u'general', 1), (u'development', 1), (u'tips', 1), (u'inclusing', 1), (u'info', 1), (u'on', 1), (u'develop
ping', 1), (u'Spark', 1), (u'using', 1), (u'an', 1), (u'IDE', 1), (u'see', 1), (u'["Useful', 1), (u'Developer', 1), (u'Tools'](<http://spark.apache.org/devel
oper-tools.html>)', 1), (u'', 1), (u'##', 1), (u'Interactive', 1), (u'Scala', 1), (u'The', 1), (u'easiest', 1), (u'way', 1), (u'to',
, 1), (u'start', 1), (u'using', 1), (u'Spark', 1), (u'is', 1), (u'through', 1), (u'the', 1), (u'Scala', 1), (u'shell', 1), (u'', 1), (u'', 1), (u'', 1), (u'',
, 1), (u'', 1), (u'./bin/spark-shell', 1), (u'', 1), (u'Try', 1), (u'the', 1), (u'following', 1), (u'command', 1), (u'should', 1), (u'return
', 1), (u'1000', 1), (u'', 1), (u'', 1), (u'', 1), (u'', 1), (u'<scala>', 1), (u'sc.parallelize(1', 1), (u'to', 1), (u'1000).count()', 1), (u'', 1),
(u'##', 1), (u'Interactive', 1), (u'Python', 1), (u'Shell', 1), (u'', 1), (u'Alternatively', 1), (u'if', 1), (u'you', 1), (u'prefer', 1), (u'Python', 1),
(u'you', 1), (u'can', 1), (u'use', 1), (u'the', 1), (u'Python', 1), (u'shell', 1), (u'', 1), (u'', 1), (u'', 1), (u'', 1), (u'', 1), (u'./bin/pyspark', 1),
(u'', 1), (u'And', 1), (u'run', 1), (u'the', 1), (u'following', 1), (u'command', 1), (u'which', 1), (u'also', 1), (u'return', 1), (u'1000',
, 1), (u'', 1), (u'', 1), (u'', 1), (u'', 1), (u'<sc.parallelize(range(1000)).count()', 1), (u'', 1), (u'##', 1), (u'Example', 1), (u'Pro
grams', 1), (u'', 1), (u'Spark', 1), (u'also', 1), (u'comes', 1), (u'with', 1), (u'several', 1), (u'sample', 1), (u'programs', 1), (u'in', 1), (u'the', 1),
(u'examples', 1), (u'directory', 1), (u'To', 1), (u'run', 1), (u'one', 1), (u'of', 1), (u'them', 1), (u'use', 1), (u'./bin/run-example', 1), (u'<class>
', 1), (u'[params', 1), (u'for', 1), (u'example', 1), (u'', 1), (u'', 1), (u'', 1), (u'', 1), (u'./bin/run-example', 1), (u'SparkPi', 1), (u'',
, 1), (u'will', 1), (u'run', 1), (u'the', 1), (u'Pi', 1), (u'example', 1), (u'locally', 1), (u'', 1), (u'You', 1), (u'can', 1), (u'set', 1), (u'the', 1), (u'M
ASTER', 1), (u'environment', 1), (u'variable', 1), (u'when', 1), (u'running', 1), (u'examples', 1), (u'to', 1), (u'submit', 1), (u'examples', 1), (u'to', 1),
(u'a', 1), (u'cluster', 1), (u'This', 1), (u'can', 1), (u'be', 1), (u'a', 1), (u'mesos://', 1), (u'or', 1), (u'spark://', 1), (u'URL', 1), (u'yarn', 1),
(u'to', 1), (u'run', 1), (u'on', 1), (u'YARN', 1), (u'and', 1), (u'local', 1), (u'to', 1), (u'run', 1), (u'locally', 1), (u'with', 1), (u'one', 1), (u'th
read', 1), (u'or', 1), (u'local[N]', 1), (u'to', 1), (u'run', 1), (u'locally', 1), (u'with', 1), (u'N', 1), (u'threads', 1), (u'You', 1), (u'can', 1), (u
```

```
Applications Places System Tue Jan 31, 10:41 PM cloudera
cloudera@quickstart:/etc/spark/conf
File Edit View Search Terminal Help
>>>
>>>
>>> rdd=sc.textFile("/user/cloudera/README.md")
>>> words=rdd.flatMap(lambda x : x.split(" "))
>>> result=words.map(lambda x : (x,1)).reduceByKey(lambda x,y:x+y).collect()
>>> print result
[(u'', 71), (u'project', 1), (u'help', 1), (u'when', 1), (u'Hadoop', 3), (u'local', 1), (u'.dev/run-tests', 1), (u'inclusing', 4), (u'graph', 1), (u'comp
utation', 1), (u'file', 1), (u'high-level', 1), (u'find', 1), (u'web', 1), (u'Shell', 2), (u'cluster', 2), (u'also', 4), (u'using:', 1), (u'Big', 1), (u'guid
ance', 2), (u'run:', 1), (u'Scala', 1), (u'Running', 1), (u'should', 2), (u'environment', 1), (u'to', 17), (u'only', 1), (u'module', 1), (u'given', 1), (u
'rich', 1), (u'directory', 1), (u'Apache', 1), (u'Interactive', 2), (u'sc.parallelize(range(1000)).count()', 1), (u'Building', 1), (u'do', 2), (u'guide', 1),
(u'return', 2), (u'which', 2), (u'than', 1), (u'Programs', 1), (u'Many', 1), (u'Try', 1), (u'built', 1), (u'YARN', 1), (u'R', 1), (u'using', 5), (u'Exa
mple', 1), (u'<scala>', 1), (u'Once', 1), (u'Spark'](<http://spark.apache.org/docs/latest/building-spark.html>)', 1), (u'and', 9), (u'Beca
use', 1), (u'cluster', 1), (u'name', 1), (u'T', 1), (u'Testing', 1), (u'optimized', 1), (u'Streaming', 1), (u'./bin/pyspark', 1), (u'SOL', 2), (u'through',
, 1), (u'GraphX', 1), (u'them', 1), (u'guide'](<http://spark.apache.org/contributing.html>)', 1), (u'[run', 1), (u'analysis', 1), (u'##xa0Contributing', 1), (
u'abbreviated', 1), (u'set', 2), (u'For', 3), (u'Scala', 2), (u'##', 8), (u'the', 24), (u'thread', 1), (u'library', 1), (u'see', 3), (u'individual', 1), (u'
examples', 2), (u'MASTER', 1), (u'runs', 1), (u'[Apache', 1), (u'Pi', 1), (u'instructions', 1), (u'More', 1), (u'Python', 2), (u'#', 1), (u'processing', 1),
(u'for', 1), (u'get', 1), (u'several', 1), (u'review', 1), (u'its', 1), (u'contributing', 1), (u'This', 2), (u'Developer', 1), (u'version', 1), (u'provides', 1), (u'
print', 1), (u'test', 1), (u'Configuration', 1), (u'supports', 2), (u'command', 2), (u'[params]', 1), (u'refer', 2), (u'available', 1), (u'be', 2), (u'Guid
e'](<http://spark.apache.org/docs/latest/configuration.html>)', 1), (u'run', 7), (u'./bin/run-example', 2), (u'Versions', 1), (u'["Parallel', 1), (u'Hadoop', 2
, (u'Documentation', 1), (u'use', 3), (u'downloaded', 1), (u'distributions', 1), (u'Spark', 1), (u'example:', 1), (u'by', 1), (u'package', 1), (u'Maven'](<
http://maven.apache.org/)', 1), (u'["Building', 1), (u'thread', 1), (u'package', 1), (u'of', 5), (u'changed', 1), (u'programming', 1), (u'Spark', 16), (u'ag
ainst', 1), (u'site', 1), (u'Maven', 1), (u'3'](<https://wiki.apache.org/confluence/display/MAVEN/Parallel+builds+in+Maven+3>)', 1), (u'or', 3), (u'comes',
, 1), (u'first', 1), (u'info', 1), (u'contains', 1), (u'can', 7), (u'overview', 1), (u'package', 1), (u'Please', 4), (u'one', 3), (u'documentation', 1), (u'
'You', 1), (u'Online', 1), (u'tools', 1), (u'your', 1), (u'page](http://spark.apache.org/documentation.html', 1), (u'threads', 1), (u'Tests', 1), (u'fast
', 1), (u'from', 1), (u'[project', 1), (u'APIs', 1), (u'>>>', 1), (u'SparkPi', 2), (u'locally', 2), (u'system', 1), (u'submit', 1), (u'examples', 2), (u'sy
stems', 1), (u'start', 1), (u'IDE', 1), (u'params', 1), (u'build/mvn', 1), (u'way', 1), (u'basic', 1), (u'README', 1), (u'<http://spark.apache.org/>', 1),
(u'It', 2), (u'graphs', 1), (u'more', 1), (u'engine', 1), (u'project', 1), (u'option', 1), (u'on', 7), (u'started', 1), (u'Note', 1), (u'N', 1), (u'usage', 1
), (u'versions', 1), (u'DataFrames', 1), (u'particular', 2), (u'instance', 1), (u'./bin/spark-shell', 1), (u'general', 3), (u'with', 4), (u'easiest', 1), (
u'protocols', 1), (u'must', 1), (u'And', 1), (u'builds', 1), (u'developing', 1), (u'this', 1), (u'setup', 1), (u'shell', 2), (u'will', 1), (u'./bin/run-exa
mple', 1), (u'following', 2), (u'Hadoop-supported', 1), (u'distribution', 1), (u'Maven', 1), (u'example', 3), (u'are', 1), (u'detailed', 2), (u'Data', 1), (
u'mesos://', 1), (u'stream', 1), (u'computing', 1), (u'is', 6), (u'in', 6), (u'higher-level', 1), (u'tests', 2), (u'1000', 2), (u'an', 4), (u'sam
ple', 1), (u'To', 2), (u'tests'](<http://spark.apache.org/developer-tools.html#individual-tests>)', 1), (u'tips', 1), (u'at', 2), (u'have', 1), (u'1000).co
unt()', 1), (u'["Specifying', 1), (u'building', 1), (u'You', 4), (u'configure', 1), (u'development', 1), (u'information', 1), (u'different', 1), (u'Tools'](<
http://spark.apache.org/developer-tools.html>)', 1), (u'MASTER-spark://host:7077', 1), (u'no', 1), (u'no', 1), (u'not', 1), (u'Java', 1), (u'that', 2), (u'storage', 1),
(u'Mllib', 1), (u'same', 1), (u'machine', 1), (u'how', 3), (u'need', 1), (u'other', 1), (u'build', 4), (u'prefer', 1), (u'online', 1), (u'you', 4), (u'if',
, 4), (u'[Contribution', 1), (u'A', 1), (u>About', 1), (u'HDFS', 1), (u'Configuration', 1), (u'sc.parallelize(1', 1), (u'locally', 1), (u'Hive', 2), (u'["Use
ful', 1), (u'running', 1), (u'uses', 1), (u'a', 8), (u'Version'](<http://spark.apache.org/docs/latest/building-spark.html#specifying-the-hadoop-version>)', 1),
(u'variable', 1), (u'The', 1), (u'data', 1), (u'class', 2), (u'built', 1), (u'building', 2), (u'yarn', 1), (u'Python', 2), (u'Thriftserver', 1), (u'proces
sing', 1), (u'programs', 2), (u'requires', 1), (u'documentation', 3), (u'pre-built', 1), (u'Alternatively', 1), (u'programs', 1), (u'local[N]', 1), (u'S
park'](<building-spark>)', 1), (u'clean', 1), (u'<class>', 1), (u'spark://', 1), (u'Learning', 1), (u'core', 1), (u'talk', 1), (u'latest', 1)]
>>>
```

=====  
CombineByKey()  
參考網站 (概

調教平行度

10	collect at <stdin>:1	2017/02/01 10:52:30	0.2 s	2/2	2/2
----	----------------------	---------------------	-------	-----	-----

Job Id	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
11	collect at <stdin>:1	2017/02/01 10:54:36	0.8 s	2/2	11/11



=====  
改變分割的需求：coalesce()、repartition

參考網站（概念）：<http://lxw1234.com/archives/2015/07/341.htm>  
=====

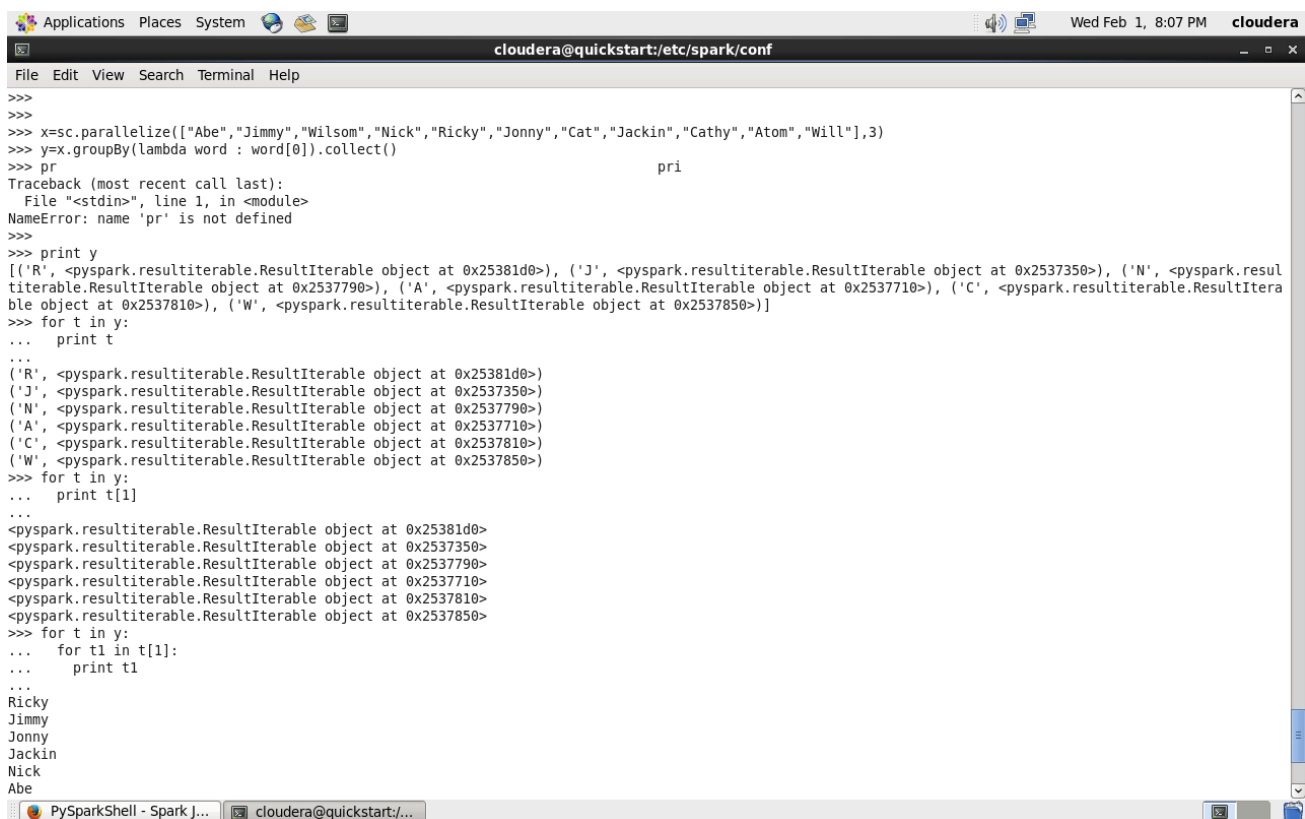
=====  
GroupBy()

原理：將元素透過function生成相對應的Key，數據就轉換成Key-Value格式，之後將key相同的元素分為一組

GroupBy和GroupByKey差異：groupByKey對key-Value型態的RDD操作，其所分組使用的key不是由指定的function產生，而是產用元素本身的Key

參考網站（概念）：<http://backtobasics.com/big-data/spark/apache-spark-groupby-example/>

參考網站（概念）：<http://blog.cheyo.net/178.html>  
=====



```
Applications  Places  System  cloudera@quickstart:/etc/spark/conf
File Edit View Search Terminal Help
>>>
>>> x=sc.parallelize(["Abe","Jimmy","Wilson","Nick","Ricky","Jonny","Cat","Jackin","Cathy","Atom","Will"],3)
>>> y=x.groupBy(lambda word : word[0]).collect()
>>> pr
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'pr' is not defined
>>> print y
[('R', <pyspark.resultiterable.ResultIterable object at 0x25381d0>), ('J', <pyspark.resultiterable.ResultIterable object at 0x2537350>), ('N', <pyspark.resultiterable.ResultIterable object at 0x2537790>), ('A', <pyspark.resultiterable.ResultIterable object at 0x2537710>), ('C', <pyspark.resultiterable.ResultIterable object at 0x2537810>), ('W', <pyspark.resultiterable.ResultIterable object at 0x2537850>)]
>>> for t in y:
...     print t
...
('R', <pyspark.resultiterable.ResultIterable object at 0x25381d0>)
('J', <pyspark.resultiterable.ResultIterable object at 0x2537350>)
('N', <pyspark.resultiterable.ResultIterable object at 0x2537790>)
('A', <pyspark.resultiterable.ResultIterable object at 0x2537710>)
('C', <pyspark.resultiterable.ResultIterable object at 0x2537810>)
('W', <pyspark.resultiterable.ResultIterable object at 0x2537850>)
>>> for t in y:
...     for t1 in t[1]:
...         print t1
...
Ricky
Jimmy
Jonny
Jackin
Nick
Abe
```

```
Applications Places System cloudera@quickstart:/etc/spark/conf
File Edit View Search Terminal Help
...
('R', <pyspark.resultiterable.ResultIterable object at 0x25381d0>)
('J', <pyspark.resultiterable.ResultIterable object at 0x2537350>)
('N', <pyspark.resultiterable.ResultIterable object at 0x2537790>)
('A', <pyspark.resultiterable.ResultIterable object at 0x2537710>)
('C', <pyspark.resultiterable.ResultIterable object at 0x2537810>)
('W', <pyspark.resultiterable.ResultIterable object at 0x2537850>)
>>> for t in y:
...     print t[1]
...
<pyspark.resultiterable.ResultIterable object at 0x25381d0>
<pyspark.resultiterable.ResultIterable object at 0x2537350>
<pyspark.resultiterable.ResultIterable object at 0x2537790>
<pyspark.resultiterable.ResultIterable object at 0x2537710>
<pyspark.resultiterable.ResultIterable object at 0x2537810>
<pyspark.resultiterable.ResultIterable object at 0x2537850>
>>> for t in y:
...     for t1 in t[1]:
...         print t1
...
Ricky
Jimmy
Jonny
Jackin
Nick
Abe
Atom
Cat
Cathy
Wilson
Will
>>> print (t[0],[i for i in t[1]])
('W', ['Wilson', 'Will'])
>>> print [(t[0],[i for i in t[1]]),for t in y]
File "<stdin>", line 1
    print [(t[0],[i for i in t[1]]),for t in y]
          ^
SyntaxError: invalid syntax
>>> print [(t[0],[i for i in t[1]])for t in y]
[('R', ['Ricky']), ('J', ['Jimmy', 'Jonny', 'Jackin']), ('N', ['Nick']), ('A', ['Abe', 'Atom']), ('C', ['Cat', 'Cathy']), ('W', ['Wilson', 'Will'])]
>>>
```

=====

cogroup()

參考網站 (概念) : <http://lxw1234.com/archives/2015/07/384.htm>

問題：要如何把value的兩層list讀取出來

=====





Python : leftOuterjoin()

A screenshot of a PySpark terminal window titled "cloudera@quickstart:/etc/spark/conf". The terminal shows a series of commands being executed in a Scala REPL. The first command is `storeAddress=sc.parallelize([("Ritual","1026 Valencia St"),("Philz","748 Van Ness Ave"),("Philz","3101 24th St"),("Starbucks","Seattle")])`. This is followed by `storeRating=sc.parallelize([("Ritual",4.9),("Philz",4.8)])` and then `storeAddress.join(storeRating)`, which results in a `PythonRDD[132] at RDD at PythonRDD.scala:43`. Finally, the command `storeAddress.join(storeRating).collect()` is executed, displaying a single tuple: `[('Philz', ('748 Van Ness Ave', 4.7999999999999998)), ('Philz', ('3101 24th St', 4.7999999999999998)), ('Ritual', ('1026 Valencia St', 4.9000000000000004)))]`. The terminal interface includes standard menu options like File, Edit, View, Search, Terminal, and Help. At the bottom, there are taskbar icons for "PySparkShell - Spark J..." and "cloudera@quickstart:/...".

Python : rightOutjoin()

=====



